

UNIVERSIDAD PERUANA UNIÓN

Facultad de Ingeniería y Arquitectura

EXAMEN DE MINERÍA DE DATOS

Análisis de Segmentación y Clasificación

student-mat + student-por Dataset	1,044 Registros	730 / 157 / 157 Partición	Random Forest Mejor Modelo
---	---------------------------	-------------------------------------	--------------------------------------

Alumno: Josue Gabriel Ochoa Mamani
UPEU · 2026

1. Dataset y Carga de Datos

Se unificaron los datasets de matemáticas (395 registros) y portugués (649 registros), resultando en 1,044 estudiantes con 34 variables. La variable objetivo aprobado fue creada binarizando G3 (aprobado si $G3 \geq 10$). No se detectaron nulos ni duplicados.

	school	sex	age	address	famsize	Pstatus	Medu	Fedu	Mjob	Fjob	reason	guardian	traveltime	studytime	failures	schoolsup	famsup	paid	activities	nursery	higher	internet	rom
0	GP	F	18	U	GT3	A	4	4	at_home	teacher	course	mother	2	2	0	yes	no	no	no	yes	yes	no	no
1	GP	F	17	U	GT3	T	1	1	at_home	other	course	father	1	2	0	no	yes	no	no	no	yes	yes	no
2	GP	F	15	U	LE3	T	1	1	at_home	other	other	mother	1	2	3	yes	no	yes	no	yes	yes	yes	no
3	GP	F	15	U	GT3	T	4	2	health	services	home	mother	1	3	0	no	yes	yes	yes	yes	yes	yes	yes
4	GP	F	16	U	GT3	T	3	3	other	other	home	father	1	2	0	no	yes	yes	no	yes	yes	no	no
5	GP	M	16	U	LE3	T	4	3	services	other	reputation	mother	1	2	0	no	yes	yes	yes	yes	yes	yes	no
6	GP	M	16	U	LE3	T	2	2	other	other	home	mother	1	2	0	no	no	no	no	yes	yes	yes	no
7	GP	F	17	U	GT3	A	4	4	other	teacher	home	mother	2	2	0	yes	yes	no	no	yes	yes	yes	no
8	GP	M	15	U	LE3	A	3	2	services	other	home	mother	1	2	0	no	yes	yes	no	yes	yes	yes	no
9	GP	M	15	U	GT3	T	3	4	other	other	home	mother	1	2	0	no	yes	yes	yes	yes	yes	yes	no

1,044
Registros totales

34
Columnas

814
(78%)
Aprobados


230
(22%)
Reprobados

0
Nulos


2. Exploración de Datos (EDA)

Estadísticas Descriptivas

Variables numéricas (1,044 registros): freetime media=3.20, goout=3.16, Dalc=1.49, Walc=2.28, absences media=4.34 (máx=75). Notas G1/G2/G3 con media ~11.2–11.3/20. La variable aprobado confirma el 78% de aprobados.




Matriz de Correlación — Hallazgos Clave



Variables	Correlación	Interpretación
G1 – G2	0.86	Muy alta — consistencia entre trimestres
G2 – G3	0.91	Muy alta — G2 predice casi directamente G3
G1 – G3	0.81	Alta — predictor fuerte
Medu – Fedu	0.64	Moderada — nivel educativo padres correlacionado
failures – G3	-0.37 / -0.38	Negativa — más reprobaciones, peores notas

Distribución de G1 (1er Trimestre)

Distribución aproximadamente normal centrada en 11. Boxplot: mediana=11, Q1=9, Q3=13, min=0, max=19. Sin outliers extremos en G1.



3. Limpieza de Datos

Sin valores nulos ni duplicados. Outliers detectados por IQR fueron conservados por representar valores educativamente válidos dentro de las escalas definidas. Los modelos de árbol y Random Forest son robustos ante valores extremos.

app

Cargar Datos

Exploración

Limpieza

Particion

Segmentación

Clasificación

Comparación

Reporte

1. Imputación de valores nulos

No hay valores nulos en el dataset actual.

2. Filas duplicadas

No hay filas duplicadas.

3. Valores atípicos (Outliers)

Método de detección

iqr

Acción

Conservar

column	n_outliers	pct_outliers
age	2	0.19
Medu	0	0
Fedu	0	0
travelttime	24	2.3
studytime	62	5.94
failures	183	17.53
famrel	77	7.38
freetime	64	6.13
goout	0	0
Dalc	52	4.98

Total de filas con al menos un outlier detectado por columna: 802

Columna	N Outliers	% Outliers	Decisión
failures	183	17.53%	Conservar — reprobaciones reales
famrel	77	7.38%	Conservar — escala 1-5 válida
freetime	64	6.13%	Conservar — escala 1-5 válida
studytime	62	5.94%	Conservar — escala 1-4 válida
Dalc	52	4.98%	Conservar — consumo real
travelttime	24	2.30%	Conservar — escala 1-4 válida
age	2	0.19%	Conservar — edad real (22 años)
Medu / Fedu / goout	0	0%	Sin outliers

4. Partición de Datos y Modelo Baseline

730

Train (70%)

157

Validación (15%)

157

Test (15%)

56

Features finales

2

Clases

The screenshot shows the Partition tool interface. At the top, a yellow banner states: "No se ha aplicado limpieza. Se usará el dataset original. Se recomienda pasar primero por la página 3 -- Limpieza." Below this, the "Configuración de variables" section shows the target variable as "aprobado" and a list of features including school, sex, age, address, famsize, Pstatus, Medu, Fedu, Mjob, Fjob, reason, guardian, traveltime, studytime, failures, schoolsup, famsup, paid, activities, nursery, higher, internet, romantic, famrel, freetime, goout, dalc, walc, health, and absences. The "Diagnóstico de la variable objetivo" section shows 2 unique classes, 0 rare classes, 2 effective classes after grouping, and 0.0% affected rows. A green banner confirms: "Variable objetivo válida con 2 clases." The "Proporciones del split" section shows a 70% train, 15% validation, and 15% test split.

The screenshot shows the Partition tool interface with preprocessing options. A green banner confirms: "Variable objetivo válida con 2 clases." The "Proporciones del split" section shows a 70% train, 15% validation, and 15% test split. The "Preprocesamiento" section shows categorical encoding set to "auto" and numerical scaling set to "StandardScaler (Z-score)". A red banner says: "Aplicar partición y entrenar baseline". Below this, a blue banner says: "Partición ya aplicada. Modifica los parámetros y vuelve a hacer clic para recalcular." At the bottom, the data counts are: Train: 730, Validación: 157, Test: 157.

Prevención de Data Leakage

El escalador StandardScaler se ajustó exclusivamente con datos de entrenamiento y se aplicó por transformación a validación y test. G1 y G2 fueron excluidas de las features porque las notas de periodos anteriores predicen G3 directamente (correlación 0.91), lo que constituiría data leakage.


Baseline (DummyClassifier — predice siempre la clase mayoritaria)

Accuracy	F1	Precision	Recall	AUC
0.7771	0.6796	0.6038	0.7771	0.5000

AUC=0.500 indica capacidad discriminativa nula — equivale a clasificación aleatoria. Cualquier modelo real debe superar estas métricas, especialmente en F1 y AUC.

5. Segmentación (Clustering No Supervisado)

Se evaluaron valores de k entre 2 y 8. El índice Silhouette determinó k=2 como óptimo (0.1965 para K-Means), el valor más alto de toda la sesión de análisis. Aunque está por debajo de 0.25, es el esperado para datos académicos continuos.



K-Means



Método del codo e Índice Silhouette por k. Inercia decrece de 15k (k=2) a 11k (k=8). Mejor k=2 con Silhouette=0.1965.

Clustering Jerárquico (Ward)

Dendrograma con fusión principal a distancia ~35. Silhouette Score = 0.2083 con k=2. Al unificar ambos datasets, el Clustering Jerárquico supera a K-Means (0.2083 vs 0.1965). Ambos valores superan 0.15, indicando estructura más definida con mayor volumen de datos.

Proyección PCA 2D

PC1 explica el 23.4% de la varianza y PC2 el 11.7%. Los clústeres se diferencian principalmente por ausentismo, consumo de alcohol y edad.




Algoritmo	Clústeres	Silhouette Score	Resultado
K-Means	2	0.1965	Bueno
Clustering Jerárquico (Ward)	2	0.2083	Mejor (seleccionado)

6. Clasificación Supervisada

Dataset: 730 train | 157 val | 157 test | 56 features | 2 clases

6.1 Árbol de Decisión (max_depth=5, min_samples_split=2)

Construye reglas de decisión recursivas basadas en impureza Gini. Genera reglas interpretables del tipo 'si higher_no=1 y guardian_father=1, entonces reprobado'.




Accuracy	F1	Precision	Recall	AUC
0.7197	0.7225	0.7254	0.7197	0.5966

Variables más importantes: higher_no (~0.45), guardian_father (~0.12), schoolsup_yes (~0.10), famrel.

6.2 Random Forest (n=100, max_depth=10, max_features='sqrt')

Ensemble de 100 árboles con muestras y features aleatorias. Reduce varianza y mejora generalización. max_features='sqrt' usa $\sqrt{56} \approx 7$ features por nodo.



Accuracy	F1	Precision	Recall	AUC-ROC
0.8089	0.7779	0.7889	0.8089	0.7475

7. Evaluación Comparativa de Modelos



Modelo	Accuracy	F1	Precision	Recall	AUC
Baseline	0.7771	0.6796	0.6038	0.7771	0.5000
Árbol de Decisión	0.7197	0.7225	0.7254	0.7197	0.5966

Modelo	Accuracy	F1	Precision	Recall	AUC
Random Forest	0.8089	0.7779	0.7889	0.8089	0.7475

Random Forest — Mejor Modelo

Accuracy=0.809 (+3.2% sobre baseline) · F1=0.778 (+9.9% sobre baseline) · AUC=0.748 (+49.5% sobre baseline). Curva ROC: AUC=0.7475 indica buena capacidad discriminativa — el modelo tiene 74.75% de probabilidad de distinguir correctamente entre un aprobado y un reprobado seleccionados al azar.

8. Conclusiones

Reporte Ejecutivo

Resumen Ejecutivo

Fecha del análisis: 21/05/2026 16:38Dataset analizado: student-mat-completo.csv + student-por-completo.csv

Registros originales

1,044

Variables originales

34

Limpeza

No aplicada

—

Partición

Train

730

Validación

157

Test

157

Variable objetivo: aprobado

Features: 56 columnas

Rendimiento de modelos (conjunto de test)

Modelo	accuracy	f1	precision	recall	auc
Baseline	0.7771	0.6796	0.6038	0.7771	0.5
Árbol de Decisión	0.7197	0.7225	0.7254	0.7197	0.5966
Random Forest	0.8089	0.7779	0.7889	0.8089	0.7475

Dimensión	Hallazgo
Dataset	Unificación de 1,044 registros, 34 variables. 78% aprobados. Sin nulos ni duplicados.
Partición	División 70/15/15 estratificada. Baseline AUC=0.500 (clasificación aleatoria).
Segmentación	Clustering Jerárquico (Silhouette=0.2083) supera K-Means (0.1965), ambos con k=2.
Clasificación	Random Forest: Accuracy=0.809, F1=0.778, AUC=0.748. Mejor en todas las métricas.
Variables clave	higher_no (~0.45 importancia), guardian_father, schoolsup_yes, goout, Medu.
Recomendación	Random Forest para producción. Identifica correctamente 8 de cada 10 estudiantes.

Mensaje para Directivos

El modelo identifica correctamente a 8 de cada 10 estudiantes que aprobarán o reprobarán, siendo un 49% más preciso que el método tradicional de predicción por mayoría. Las expectativas académicas del estudiante (querer continuar estudios superiores) es el predictor más importante.

Universidad Peruana Unión · Josue Gabriel Ochoa Mamani · UPEU 2026